

# 谁来给尺子打分： $\sigma$ 坐标伪流环境中的代理指标可靠性探索

## 一、问题与证据

### 1.1 真实问题或需求

地形跟随 ( $\sigma$ ) 坐标是区域海洋模式的主流选择，其优势是贴合地形。但是正因如此，代价是坐标面倾斜时，压力梯度被拆成两个量级相当、符号相反的项，两者相减产生截断误差，在陡坡处凭空产生并不存在的流动。

我们用一个标准的孤立海山（外加纬向风强迫）的例子来量化。在地形、层数、风应力均相同的条件下，分别取用 MITgcm 的  $z$  坐标和 ROMS 的  $\sigma$  坐标，前者作为独立参照：第一天结束时 MITgcm 的最大流速只有 9.2 cm/s，而 ROMS 达到 100 cm/s。差距不是偶发，全程系统地大 10 - 16 倍，在真值走到惯性振荡节点时达到 99 倍。第二天真值几乎归零，而  $\sigma$  坐标仍有 86 cm/s。而把横向黏性加到区间端点 2747 m<sup>2</sup>/s， $\sigma$  坐标的最大流速仍是真值的 1.95 倍，无法救回。这直接影响陆坡、海山、峡湾等陡地形海域的模拟可信度——而这些恰恰是海洋动力学最关心的区域。

**$\sigma$  坐标凭空造出比真实流场大一个量级以上的伪流**




图 1  $\sigma$  坐标伪流与独立真值的正面比对。两侧模式使用同一地形 (48×48, 峰高 80 m)、同 13 层、同风应力 ( $\tau=0.1$  N/m<sup>2</sup>)、同 3 天积分，唯一差别是垂向坐标。(a) 全域最大流速的时间序列。(b)  $\sigma$  坐标与真值之比：系统性大 10 - 16 倍；第 2 天真值走到惯性振荡节点、几乎归零，比值达 99 倍。

### 1.2 为什么尚未被结构化

这个问题不是没人做，是三十年没做完。较早系统研究这个误差的 Mellor 在 1998 年承认：“an error that did not disappear and that has not been understood by us or, apparently, others”——误差没有消失，他和其他人都没弄明白。四年后 Berntsen 写道，这场争议 “is still worrisome to at least some of the users”，至今还让一部分使用者头疼。他还留下两句到今天仍然成立的警告：在理想算例上得到的结论，放到真实算例上未必成立；想把这个误差压下去，黏性得乘上大约一百倍。我们自己的论文也得到类似的结论：不存在一个通用的最优控制方案，只能一个算例一个算例地权衡。最新的修正方案是 Chen 和 Lai 在 2024 年提出的，发表至今被引为零。

还有一层更要紧。这个领域连“怎么判断一个控制方案好不好”都没有共识。真值平时测不到，判断只能靠看得见的读数当替身——行话叫代理指标。可我们在同一个项目里就三次撞见它失灵：换个层数，固定层号的指标就没了意义；单点读数和体积统计给出相反的结论；压住伪流——模式凭空算出来的假流——的操作，把真实的内潮也一起抹掉了。大家都在争“哪个方案好”，却没人先问一句：你用来打分的尺子，本身准不准？这就是我们切入的位置。

### 1.3 研究价值与合适切片

我们不做“解决  $\sigma$  坐标误差”这种大题目。切下来的这一片是：找一个真值可以独立测出来的算例，检验“判断控制方案好坏”的那把尺子本身到底可不可信。

这是研究问题，不是调参。尺子不准，在它上面做的一切优化都白费。而尺子准不准，在平时的科研里恰恰没法回答——因为平时没有真值。

这活也天然适合交给智能体 (Agent)。想知道尺子在哪儿准、在哪儿不准，就得在大量配置上一个一个试。每试一个点都要真跑一次模式，一次约两分钟。这种又多又重复的事，人做太贵，机器做刚好。我们已经累计跑了 367 次，其中 345 次有效；并发开到 16 路时吞吐最高，每分钟能出 34 个结果。

这个切片也经得起评委查。我们故意只给陡海山这一个地形配了独立真值——真实科研里真值通常就是缺席的，环境如实反映这一点。也正因为留了这一条真值通道，“尺子可不可信”才成了一个可以判定的问题。

赛题讲解开头第一句就是古德哈特定律：当一个指标成为目标，它就不再是一个好指标；并鼓励参赛者去定义“在真实科学环境下什么是一个好指标”。我们做的正是这件事。按讲解的创新矩阵自评，本作品属“新环境加新问题”一档。

## 二、环境接口

### 2.1 固定规则

我们用 ROMS 进行求解，算例为风场强迫下的孤立海山流场算例，垂直分层 13 层，横向纵向网格均为 48 个。纬向风应力取  $0.1 \text{ N/m}^2$ ， $DT=10 \text{ s}$ 。单核运行可原样复现。地形可以三选一：陡海山（r26steep）是主算例，也是唯一配了独立真值的；第二座是 MITgcm 标准海山（mit）；平底（flat）用来作对照——海底是平的，坐标面不倾斜，这类误差从根上就不会出现。求解器的编译选项和我们原始科研运行用的那套逐项相同，二进制的指纹（sha256）存了档，从源码用一条脚本就能重新编出来。环境还做了两条合法性检查：整个水体的体积相对漂移只有  $+7.2 \times 10^{-9}$ ，相当于机器精度；温度超调  $+0.251/-0.815 \text{ }^\circ\text{C}$ ——没有热通量时温度本不该越界，越出去的部分本身就是数值伪迹。

### 2.2 观察 / 行动 / 反馈

Agent 每一步提交一组配置，环境真跑一次求解器，把读数返回给它。

它能动的有七个：地形（三选一）、横向黏性 VISC2、双谐波黏性 VISC4、背景垂向黏性 AKV\_BAK、示踪物扩散 TNU2、积分步数 ntimes、随机种子 seed。它能看到的读数有：最大流速、全域均方根流速、800 米以深的均方根流速、表层最大流速、无量纲比值 uv\_ratio、温度极值，以及是否完赛、是否崩溃、完成比例。还有一些数放在它够不着的地方：和真值比出来的误差；技巧评分——这个分以恒零模型（一个永远输出零的模型）为参照，0 分就等于什么都不做；还有真值配对的凭证。

设计上有两条硬规矩：评分器它改不了，只能提交配置换读数；数值它算不了，所有数都由固定代码算好，语言模型只管挑下一步试什么。

另外有四道检查，每一道都是踩过坑之后才加的：动作空间体检，抓“旋钮拧了没反应”；配置回显自检，抓“替换没生效但不报错”；每条记录都绑上二进制指纹，抓“结果早就过期了没人发现”；还有一个结论质疑器，抓“结论下得太快”。

智能体只能提交配置换取读数——真值藏在它够不着的地方




图 2 环境接口（已实现，scripts/env2.py）。智能体只能提交配置换取可见读数，改不了评分器；真值与评分藏在其工作区之外，且只配给陡海山一个地形——这是刻意的：真实科研中真值通常缺席。

### 2.3 记录与预算

每跑一次，就往台账里写一行：动作、看得见的读数、藏起来的量、耗时、二进制指纹。并发能力实测过：单核每分钟 2.80 个结果；开到 16 路最快，34.09 个；再往上开到 128 路反而掉到 24.73。瓶颈不在 CPU，在内存带宽和读写——这本身也是一条可复现的工程结论。

## 三、发现信号与参照

### 3.1 什么算发现

什么算发现，我们在动手之前就定死了：发现，就是代理指标和真值判据对不上的具体方式，而且必须落在台账的字段上，谁都能查。三个实例。

**实例一：我们自己的评估器，最高分属于“什么都不产生”。**恒零模型的误差只有 2.532；正常跑出来的默认配置，反而是 7.622，差了三倍。后来换成以恒零为参照的技巧评分，44 个配置没有一个是正分，最好的也只有 -0.184。这不是没调好。真值的能量几乎全在最上面一层：表层  $9.23 \text{ cm/s}$ ，往下就只剩不到  $0.02 \text{ cm/s}$ ；风的影响深度只有 0.61 米，还没第一层厚。而伪流是铺满整个水柱的——伪流比整个真信号还大。靠调黏性救不回来。这从数值上证实了我们论文的结论。

**实例二：目标怎么说，决定 Agent 怎么作弊。**我们让大语言模型来当探索者，12 轮，每轮至多 10 步。轮与轮之间只改目标那一句的说法，一共三种说法，这里展开前两种（第三种是明示邀请它质疑，3 轮，用

来测能力上限)。目标写成“把深层读数降到最低”时(5轮),它把89.8%的步数都花在平底对照上,五轮全部把“最优”报在平底,没有一轮怀疑过指标本身。目标改成“弄清楚误差受什么控制”时(4轮),平底占比降到18%,四轮全都在看不到真值的情况下自己起了疑,说法各不相同,例如:“深层读数小,可能只是平底本身没有地形驱动,而不是数值误差真的更低。”它手里没有真值,却推断出了自己需要真值。这组实验还抓到我们一个真bug:它报告“同样的配置读数差了一个量级”,我们一查,是我们给它看的历史表——台账的删减版——把积分步数滤掉了。它的推理是对的,错的是我们的观测接口。修好之后,它接着指出了又一条刷分路径:把积分时间缩短,误差来不及长起来,平底上光这一项就能差出28到34倍。

目标怎么说,决定智能体怎么作弊




图3 12轮大语言模型实测(每轮至多10步)。条件A的目标是“把deep\_rms\_800降到最低”,条件B是“弄清楚误差受什么控制”,条件C在B之上明示邀请质疑。(a)各条件耗在平底对照上的步数占比。(b)各条件质疑测量精度与质疑指标本身的轮数。(c)三条刷分路径能把代理指标“改善”的倍数(同参数配对中位):换到平底224倍、黏性增至 $3 \times 10^4 \text{ m}^2/\text{s}$  62倍、积分缩短到0.17天28倍——三条都不是解决问题,而是让问题来不及或没机会发生。

**实例三:最笨的搜索靠换地形刷分。**随机搜索和网格搜索把“最优”报在平底上,读数0.026;二分和贝叶斯优化报在陡海山上,读数2.021,两边差78倍。必须说实话:后两个躲过陷阱不是因为聪明,是它们被写死了只搜陡海山。陷阱设在一个只有部分搜索者会走进去的方向上。

三条刷分路径——换平底、把黏性拧到荒谬、缩短积分——共用同一个机制:不是解决问题,而是让问题来不及发生、或者没机会发生。一句话,让一切变小。由此我们定下三条原则,一把抗刷分的尺子得满足:第一,量在真值恒等于零的地方,这样量到的就全是误差;第二,只在不动真值的旋钮上比较;第三,做成无量纲的比值——分子分母一起缩,比值不动,“让一切变小”就刷不动它。第三条我们做了实测:从15376个候选里穷举出一个比值指标uv\_ratio,排序能力只掉了4%,三条刷分路径全部失效。再把它放回环境里重跑一遍实验,条件完全不变,只换目标指标:平底占比从89.8%掉到7.5%，“最优在平底”从五轮全中(5/5)变成四轮零中(0/4)。发现问题、量出代价、找到机理、造出修复、放回去验证——闭环走完了。

**新指标:排序能力几乎不变,抗刷分从0到100**




图4 新旧指标的两项得分(均为0-100)。排序能力得分=实例内与隐藏技巧评分的秩相关绝对值 $\times 100$ ;抗刷分得分=同参数(陡海山,平底)配对中不被“换地形”刷穿的比例 $\times 100$ 。旧指标为深层流速读数deep\_rms\_800,新指标为无量纲比值uv\_ratio:排序能力仅从96到92,抗刷分从0到100。

### 3.2 平凡解 / 随机 / 无干预

参照系从笨到聪明排了九档,做完八档:恒零模型(技巧评分恒0,44个配置无一赢过它)、无干预基线(深层8.231,评分-8.065)、单调加黏性的平凡解、随机采样、已知会崩的配置当回归测试、领域常识(横向黏性通常取 $1-100 \text{ m}^2/\text{s}$ ,代理“最优”却在三万,物理上荒谬)、高斯过程加贝叶斯优化的非平凡基线、会推理的大语言模型(12轮实测)。官方要求的平凡参照、随机或无干预、非平凡基线,分别由第2档、第1加3档、第6档满足。第7档人类专家轨迹没做完,如实标“待补”。

### 3.3 最低成功与失败标准



标准都在探索之前定好。成功任一即可：S1, Agent 自己识别出“可见指标不足以判断好坏”——已达成（“弄清楚”条件四轮全中；“最小化”条件五轮零中，如实上报）；S2, 找到技巧评分为正的配置——至今无一；S3, 找到台账外的新组合且结论被真值验证。失败三条：F1, 把最优报在平底——目标定义有漏洞，不怪 Agent；F2, 只会单调加黏到荒谬——反馈不足；F3, 赢不过贝叶斯基线——上限划清，如实上报。两条明确不算失败：“不存在通用最优配置”是重现论文结论；“技巧评分上不了零”是关于  $\sigma$  坐标本身的真结论。修订规则：S2 长期不达成，问题改写成“解释为什么不存在好配置”；F1、F2 反复，毛病在目标函数，改环境而非换 Agent。

## 四、最小验证计划

### 4.1 一次试跑怎么做

这次试跑回答一个问题：把看得见的指标压低同样的幅度，不同旋钮对真信号的破坏一样吗？输入是四样：求解器二进制（指纹 b50851d9...）、控制文件、两个地形（陡海山加平底）、配好的真值。四步：先跑动作空间体检，确认每个旋钮真的有反应；再扫四个旋钮（VISC2、VISC4、AKV\_BAK、TNU2），56 次；然后跑对应的真值，27 次；最后跑分析脚本——纯固定代码，不经过语言模型。16 路并发，墙钟约 25 分钟。产出四个文件加一张图。关键证据：三个横向的旋钮能把代理指标压低 46% 到 81%，真信号纹丝不动，变幅 0.00%；垂向那个旋钮只压低 23%，却把 89.18% 的真信号毁了——在代理指标上，这两类操作看起来没有任何区别。配置回显自检全程通过。

### 4.2 主要风险与失败路径

最先要防的，是优化器靠崩溃刷分。我们设了三道门：完赛门控、崩溃标志、技巧评分。崩溃标志曾经失灵过——ROMS 的报错写的是“Blows up”，我们的代码找的是“BLOWUP”——后来两种写法都认，已修。

最危险的一类是“跑完了、没报错、结果是垃圾”。我们撞上过三回：sed 替换没匹配上，五次运行用了同一套配置；编译选项没编进去，旋钮拧了毫无反应；MITgcm 打印“正常结束”，输出却全是 NaN。三回的退出码都是 0。对策：一次运行算不算数，必须由结果本身的性质来定，不能信退出码。还有一类，结果早就过期了没人发现——也真发生过。对策是每条记录都绑上二进制指纹。

最后如实交代这个环境最大的缺口，和我们补救的结果。此前 Agent 只能抱怨“这个指标不够”——环境里根本没有“提出新指标”这个动作。这个赛期里我们把动作补上了：让它用给定的积木自己提议指标，由藏在工作区外的评估器拿真值来检验。结果是 30 轮提议，其中 20 轮是格式有效的候选指标，没有一轮通过检验。它每一轮都能把“无量纲比值抗缩放”的道理讲对，却始终没把分子放到真值恒为零的那个子空间上；而同样的判据下，从 15376 个候选里穷举，能找出 204 个通过的。会讲原理，不等于找得到答案；缺的不是动作接口，是探索覆盖。这和我们另一组实验的结论一致——让它预测没跑过的配置再真跑对答案，预测得准不准，取决于它去过哪些地方，不是它多会推理。官方 FAQ 说，一个非平凡的基线可能比复杂的 Agent 更强。这一条我们照实比了，也照实报。

### 4.3 复现与开源计划

数据全部自产。ROMS 这边和 MITgcm 真值那边都能从源码重建，各一条构建脚本，一个约五分钟、一个约三分钟；重建出的 MITgcm 和官方发布的参考运行逐位一致。依赖全是开源的：ROMS/COAWST 用 LGPL 协议，MITgcm 也是开源协议，再加上 numpy、netCDF4、matplotlib、scikit-learn。复现方式：单一入口 env.step()，每次运行一个隔离目录，全部相对路径，每条记录带二进制指纹。开源边界：环境和 Agent 框架全部开源；已发表论文的结论只作参照引用，不复述。训练与推理源代码已随本文档一并提交，随机种子与关键参数在代码中体现，外部依赖已注明来源与版本。

## 五、团队介绍

### 5.1 成员背景

焦昕远，清华大学博士生，海洋数值模式方向。日常研究就在本作品的问题域里：关于  $\sigma$  坐标伪流的维持机理与控制策略的论文已成稿（投 Communications Earth & Environment），本作品的算例设置、MITgcm 真值对照方法和“不存在通用最优控制方案”的结论，都来自这项研究。长期做海洋、大气数值模式的源码级开发与验证，用过的模式包括 ROMS、MITgcm、WRF、OpenFAST。

### 5.2 团队分工

单人参赛。选题与切片、环境设计与搭建、全部实验、正文撰写：焦昕远。

### 5.3 团队成果

一、 $\sigma$  坐标伪流机理论文（第一作者，投稿中）——本作品的领域基础，其结论在本环境中被独立数值证实。二、PAC2026 并行应用挑战赛·优化组（队长）：张量缩并与 Indexer 算子优化，四个测例较官方基准快 7 至 155 倍，全部通过精度校验。三、MCC2026 海洋计算挑战赛：海洋热浪诊断指标计算，双节点 10.7 秒完赛，对官方 MATLAB 单核基线约 7350 倍加速，精度 RMSE 为 0。四、指导风暴潮机器学习预报方向的学生研究（期刊论文修改中）。